AES519: Bioestadística

Felipe Osorio

https://faosorios.github.io

Instituto de Matemática Fisica y Estadística, UDLA

Información, Sección 205

Horario:

Clases: Jueves, 14:20-15:20 y 15:30-16:30 hrs. Sala A403
Ayudantes: Denisse Guzmán y Javier Matos.
Sección 229: Sala B504, Sección 230: Sala B503, ambos Viernes 14:20 hrs.

Contacto:

E-mail: felipe.osorio.salgado@edu.udla.cl.
Web: https://github.com/faosorios/AES519

Evaluación:

Se realizará **2 Pruebas**, **3 Controles** (Ejercicios) y **Examen**.

Fechas:

Cátedra: 23-Abr, 18-Jun, 25-Jun (recuperativo), 09-Jul (examen).

Ejercicios: 03-Abr, 08-May, 05-Jun.

Información, Sección 206

Horario:

Clases: Jueves, 10:50-11:50 y 12:00-13:00 hrs. Sala A401
Ayudantes: Johana Urra y Román Montaña.
Sección 231: Sala B503, Sección 232: Sala B506, ambos Jueves 08:30 hrs.

Contacto:

E-mail: felipe.osorio.salgado@edu.udla.cl.
Web: https://github.com/faosorios/AES519

Evaluación:

Se realizará **2 Pruebas**, **3 Controles** (Ejercicios) y **Examen**.

Fechas:

Cátedra: 23-Abr, 18-Jun, 25-Jun (recuperativo), 09-Jul (examen).

Ejercicios: 02-Abr, 07-May, 04-Jun.

Criterio de aprobación

Criterio de aprobación:

La nota final (NF) en la asignatura se calculará de la siguiente forma:

$$NF = 0{,}5\,\overline{P} + 0{,}2\,\overline{E} + 0{,}3\,Examen,$$

donde

$$\overline{P} = \frac{1}{2}(P_1 + P_2), \qquad \overline{E} = \frac{1}{3}(E_1 + E_2 + E_3),$$

corresponde al promedio de las pruebas y de los ejercicios, respectivamente.

Reglas adicionales

- Se llevará un control de asistencia.
- Se puede realizar preguntas sobre la materia en cualquier momento.
- Los alumnos deben apagar/silenciar sus teléfonos celulares durante clases.
- Conversaciones sobre asuntos ajenos a la clase no serán tolerados. Otros estudiantes tiene derecho a asistir clases en silencio.
- Al enviar algún e-mail al profesor, identificar el código de la asignatura en el asunto (AES519).
- E-mail será el canal de comunicación oficial entre el profesor y los estudiantes.

Reglas: sobre las pruebas

- Será permitido el uso de una calculadora científica simple (no del celular).
- Es derecho del estudiante conocer la pauta de corrección la que será publicada en la página web del curso.
- El uso de lápiz grafito es aceptado. Sin embargo, inhabilita al estudiante de pedir recorrección.
- Pedidos de recorrección deben ser argumentados por escrito.
- Cualquier tipo de fraude en prueba (copia, WhatsApp, suplantación, etc.) puede implicar la apertura de un proceso disciplinario.

Orientaciones de estudio

- Mantener la frecuencia de estudio de inicio a final del semestre. El ideal es estudiar el contenido luego de **cada** clase.
- Estudiar primeramente el contenido dado en clases, buscando apoyo en las referencias bibliográficas.
- Las referencias son fuentes de ejemplos y ejercicios. Resuelva una buena cantidad de ejercicios. No deje esto para la víspera de la prueba.
- Buscar las referencias bibliográficas al inicio del semestre, dando preferencia a las principales y complementarias.

Programa del curso

- Introducción y conceptos básicos.
- Estadística descriptiva.
- Cálculo de probabilidades.
- Inferencia estadística.

Bibliografía

Díaz, V. (2012).
Metodología de la Investigación Científica y Bioestadística.
RIL Editores, Santiago de Chile.

Milton, J.S. (2007)
Estadística para Biología y Ciencias de la Salud (3ra Ed.).
McGraw-Hill, México, DF.

Walpole, R.E., Myers, R.H., Myers, S.L., Ye, K. (2012).
Probabilidad y Estadística para Ingeniería y Ciencias (9a Ed.).
Pearson, México, DF.

Motivación mediante ejemplos

- Desempeño en la prueba SIMCE.
- Trastorno transitorio del sueño.
- Evaluando el grado de similaridad entre 2 imágenes.
- Ideas sobre el proceso de modelación.

Ideas subyacentes

"Todos los modelos son errados, pero algunos son útiles."

– George Box.

"Aunque puede parecer una paradoja, toda la ciencia exacta está dominada por la idea de aproximación."

– Bertrand Russell.

Principio KISS: "Keep It Short and Simple."

– Clarence "Kelly" Johnson.

El éxito de Google: Aplicar el principio KISS[1]

Evolución de Yahoo vs. Google:

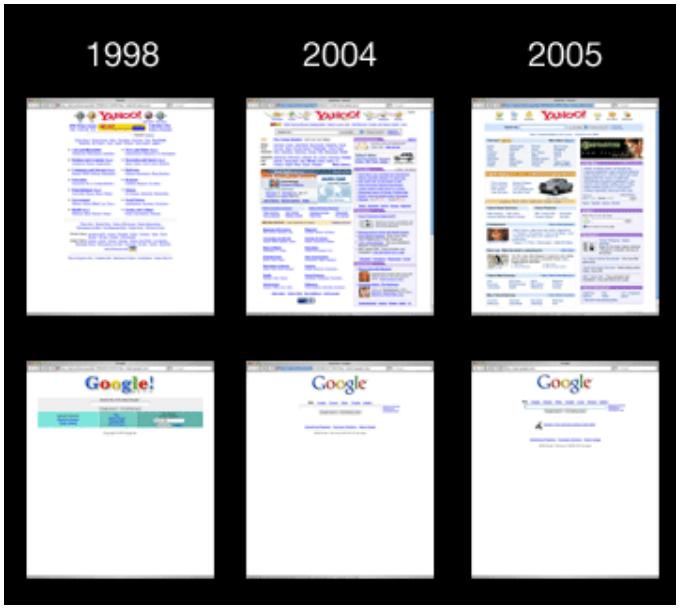

Cuota de mercado de los motores de búsqueda:

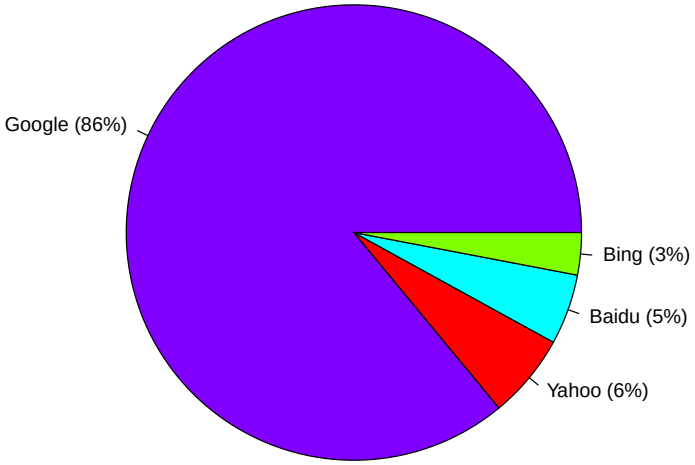

[1] En estadística este se conoce como Principio de Parsimonia.

Datos del SIMCE

Desde 1988 el SIMCE evalua los resultados de aprendizaje de los estudiantes del sistema de educación chileno.

Objetivos:

- Describir el comportamiento del aprendizaje de los estudiantes.
- Determinar si existe diferencias significativas entre el tipo de dependencia (municipal, subvencionado, particular).

Características del problema:

- Mediciones de un mismo individuo (estudiante) a través del tiempo (4º y 8º básico, 2º medio).[2]
- Datos disponibles para los años 2007, 2011 y 2013, pruebas de Lenguaje y Matemáticas.
- Aproximadamente 133K estudiantes para ser analizados (base de datos de mediano porte).

[2] Conocido como: datos con estructura longitudinal.

Datos del SIMCE[3]

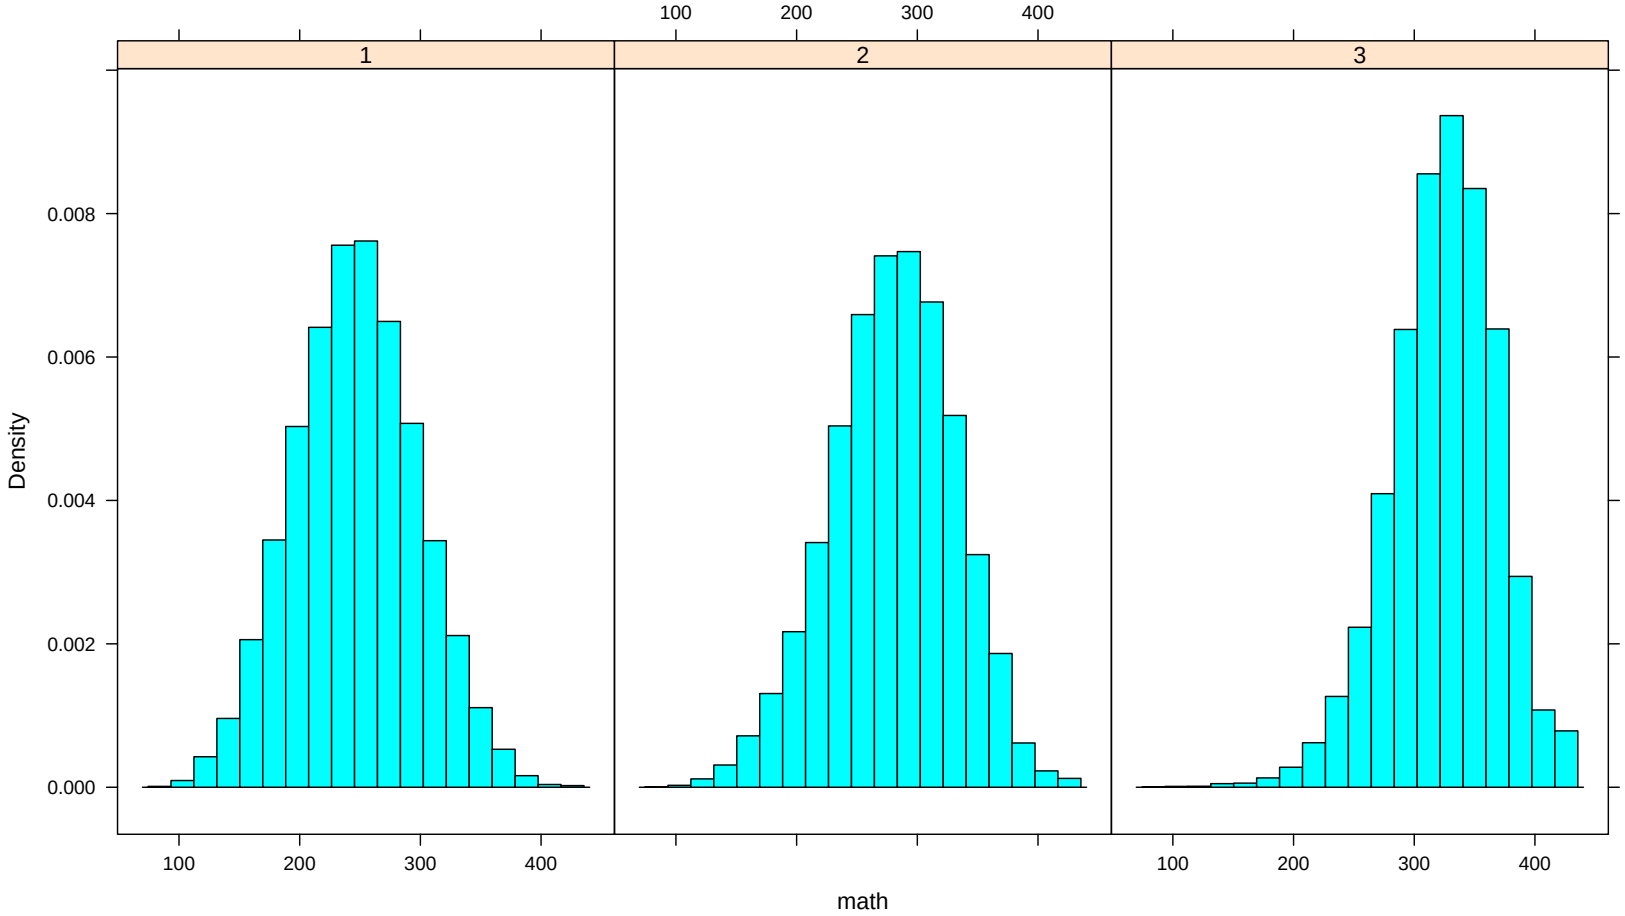

Figura: histograma puntajes matemática.

[3] colegios, 1: municipales, 2: subvencionados y 3: particules.

Datos del SIMCE

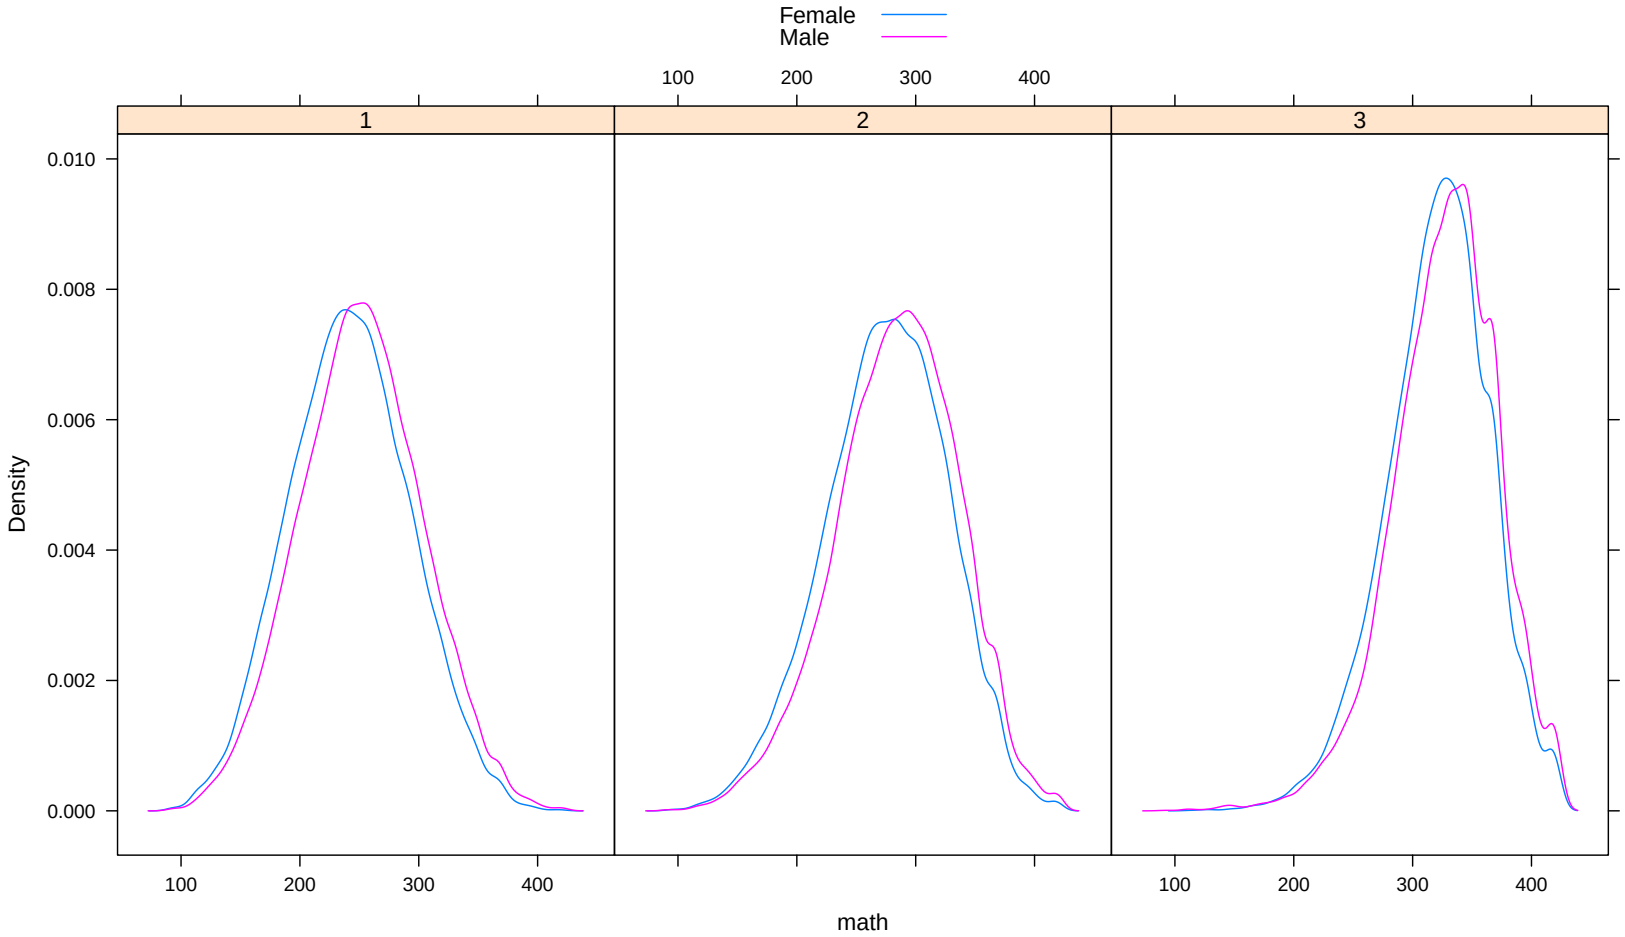

Figura: densidad puntajes matemática, organizados por género.

Datos del SIMCE

```
## Base de datos con aproximadamente 133K individuos
> SIMCE
          Sex type math04 math08 math10  spa04  spa08  spa10
1        Male    1 338.86 303.94 372.51 342.74 327.92 317.38
2      Female    2 301.98 256.04 324.65 298.30 263.12 322.40
3      Female    1 258.45 263.44 225.95 192.59 206.72 216.66
4        Male    2 233.13 323.76 288.60 268.91 274.84 251.44
5        Male    1 284.17 276.37 293.11 236.55 261.67 283.78
6        Male    1 248.64 259.76 210.17 254.34 252.15 280.53

...

132947 Female    2 211.78 254.21 246.78 244.97 286.21 269.24
132948 Female    3 285.18 315.25 354.90 303.95 341.67 315.81
132949   Male    1 259.05 232.65 224.18 305.65 195.92 217.71

```

Trastorno transitorio del sueño (Svetnik et al., 2007)

Svetnik et al. (2007)[4] llevaron a cabo un estudio clínico diseñado para comparar dos procedimientos para diagnosticar trastornos transitorios del sueño mediante métodos automatizado y semiautomatizado de registros polisomnográficos (PSG).

El estudio consideró a 82 pacientes a los que se les administró un medicamento inductor del sueño (Zolpidem 10 mg). Las mediciones de la latencia del sueño persistente[5] (LPS) se obtuvieron utilizando seis métodos diferentes.

Nos enfocaremos en dos de estos métodos: método de puntuación totalmente manual (Manual) y puntuación automatizada mediante el software Morpheus (Automático).

Sea (X_i, Y_i), para $i = 1, \ldots, 82$, las mediciones $\log(\mathrm{LPS})$ obtenidos con los métodos manual y automático, respectivamente.

[4] SLEEP **30**, 1562-1574.

[5] Desde el apagado de luces hasta el inicio de 10 minutos de sueño ininterrumpido.

Trastorno transitorio del sueño (Svetnik et al., 2007)

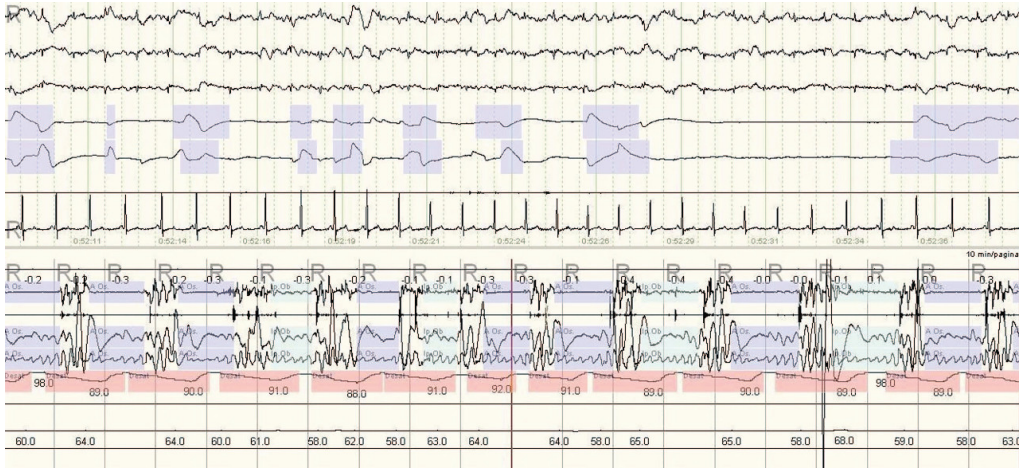

Trastorno transitorio del sueño (Svetnik et al., 2007)

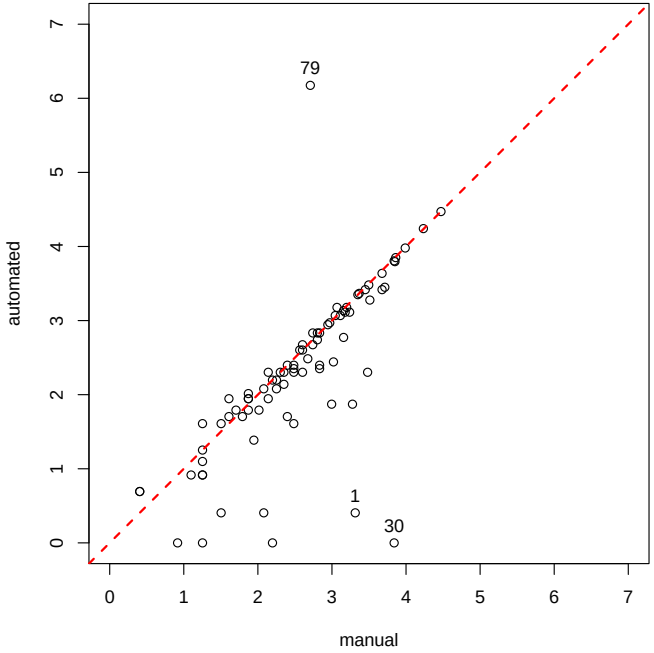

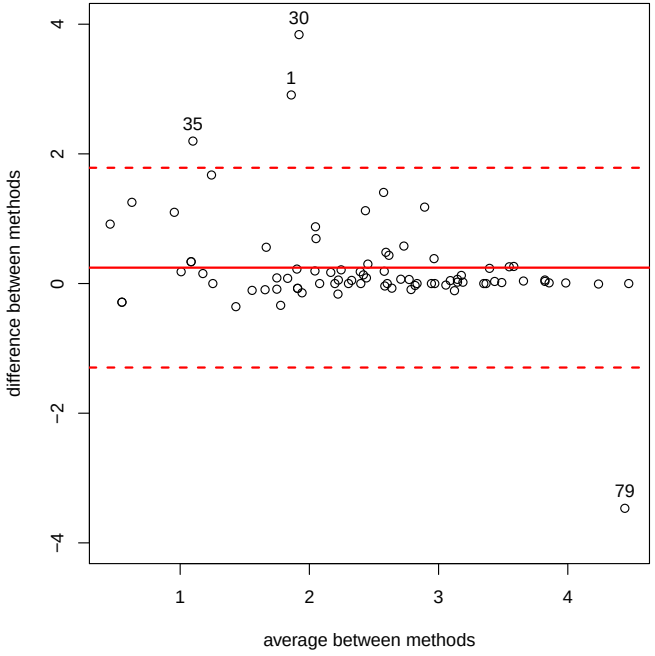

Imagen Lenna[6]

Imagen en formato PNG de tamaño 512×512

[6] Para más detalles sobre esta imagen, visite: www.lenna.org

Imagen Lenna: Visualizando cada canal de color[7]

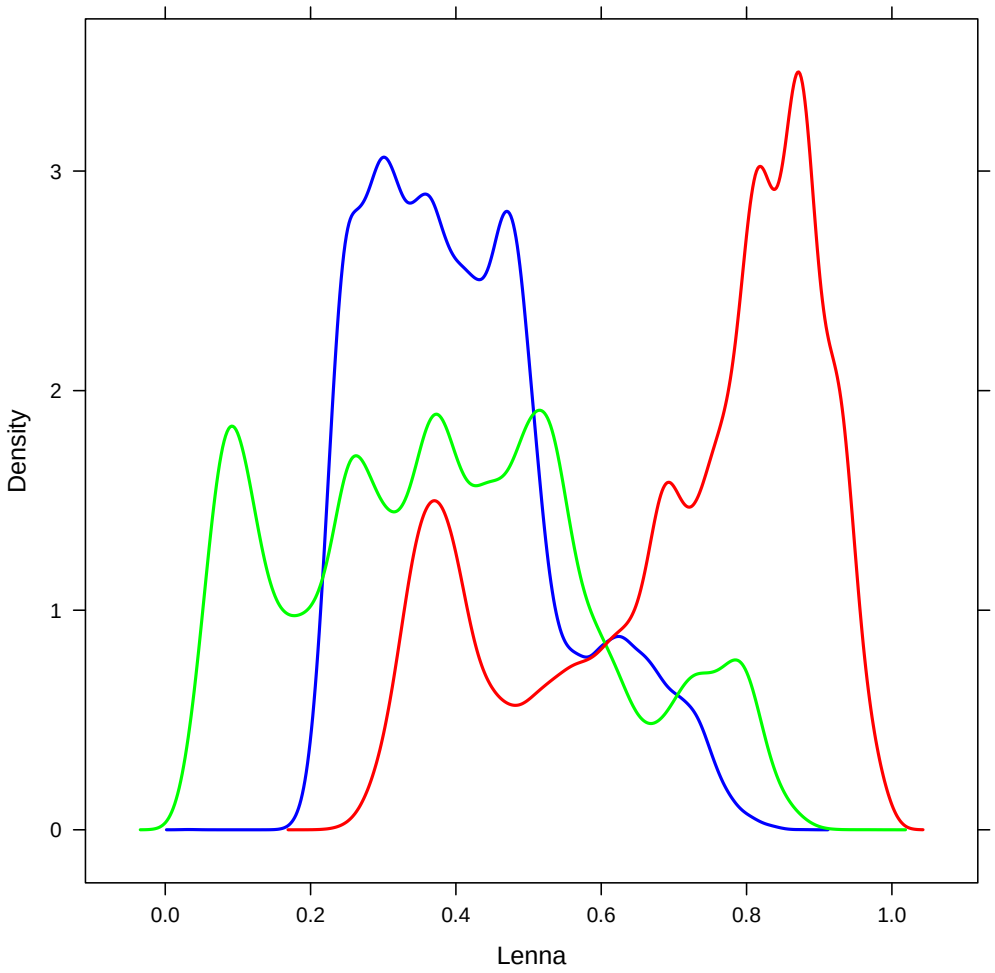

[7] Cantidad de datos: $512 \times 512 \times 3$ (canales RGB) $= 786\,432$ observaciones.

Lenna con contaminación “sal y pimienta”

(a) Imagen original [8]

(b) Ruido sal-y-pimienta $(10\,\%)$

[8] Usando filtro LUMA: $0{,}30\,R + 0{,}59\,G + 0{,}11\,B$.

Similaridad entre imágenes

- Existen diversos enfoques para estudiar la similaridad entre dos imágenes, señales o (en general) procesos.
- El objetivo es intentar emular la habilidad del ojo humano para evaluación la semejanza.
- Se ha diseñado índices para estudiar el desempeño de algoritmos para problemas como: compresión o restauración de imágenes, entre otros.
- Se desea un coeficiente apropiado que combine la luminosidad, contraste y estructura entre las imágenes. Este tipo de coeficientes son llamados índice de similaridad estructural (SSIM).

Índice de similaridad estructural (SSIM)

Definición:

Sean $\boldsymbol{x}, \boldsymbol{y}$ dos imágenes. El índice SSIM es definido como (Wang et al., 2004):[9]

$$\mathrm{SSIM}(\boldsymbol{x}, \boldsymbol{y}) = l(\boldsymbol{x}, \boldsymbol{y})^{\alpha} \cdot c(\boldsymbol{x}, \boldsymbol{y})^{\beta} \cdot s(\boldsymbol{x}, \boldsymbol{y})^{\gamma},$$

donde α, β y γ son parámetros no negativos,

$$l(\boldsymbol{x}, \boldsymbol{y}) = \frac{2\,\overline{x}\,\overline{y} + c_1}{\overline{x}^2 + \overline{y}^2 + c_1}, \qquad c(\boldsymbol{x}, \boldsymbol{y}) = \frac{2\,s_x\,s_y + c_2}{s_x^2 + s_y^2 + c_2},$$

$$s(\boldsymbol{x}, \boldsymbol{y}) = \frac{s_{xy} + c_3}{s_x\,s_y + c_3},$$

$\overline{x}$, $\overline{y}$, s_x^2, s_y^2 y s_{xy} representan los promedios muestrales, varianzas y covarianza de $\boldsymbol{x}$ y $\boldsymbol{y}$.

Las constantes c_1, c_2 y c_3 garantizan la estabilidad cuando denominadores son cercanos a cero.

[9] IEEE Transactions on Image Processing **13**, 600-612.

Lenna y algunas distorsiones de Lenna[10]

(a) Imagen original

(b) Mean shift

(c) Ruido salt-pepper

(d) Ruido speckle

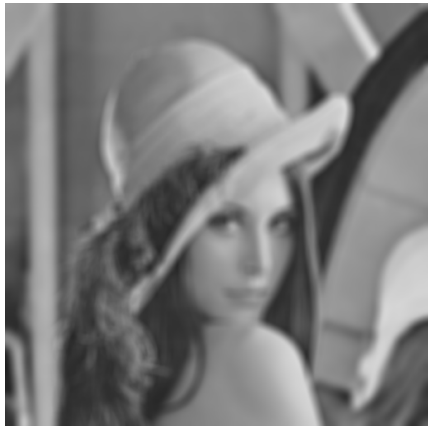

(e) Blurring

(f) Compresión

[10] SSIM: (a) 1.000, (b) 0.989, (c) 0.649, (d) 0.441, (e) 0.346 y (f) 0.288.

El problema del modelado

Considere la función

$$Y = \text{sen}\{2\pi(1-x)^2\},$$

cuyo gráfico es dado por:

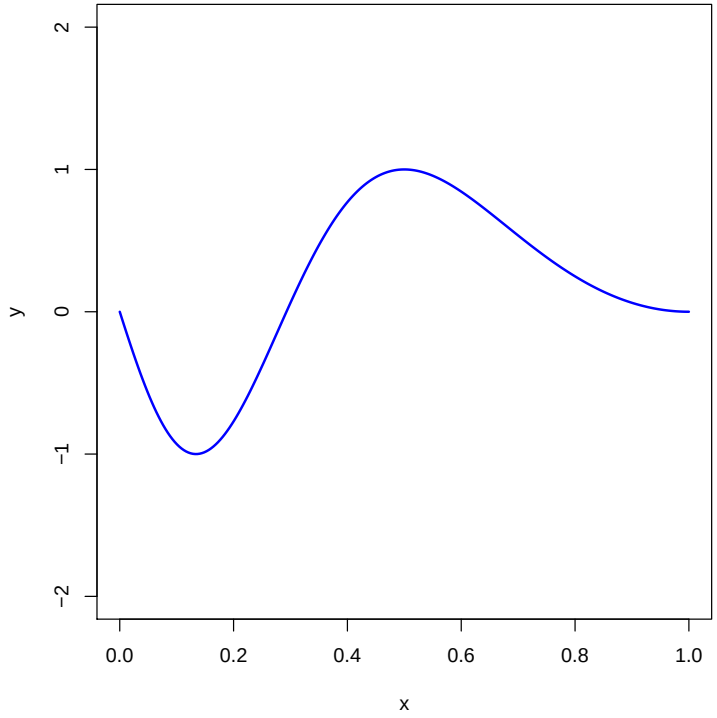

El problema del modelado

Suponga que "generamos" datos, usando

$$Y_i = \text{sen}\{2\pi(1 - x_i)^2\} + \sigma\epsilon_i, \qquad i = 1, \ldots, 100,$$

donde $x_i \sim \mathsf{U}(0, 1)$, $\epsilon_i \sim \mathsf{N}(0, 1)$ y $\sigma = 1/2$,

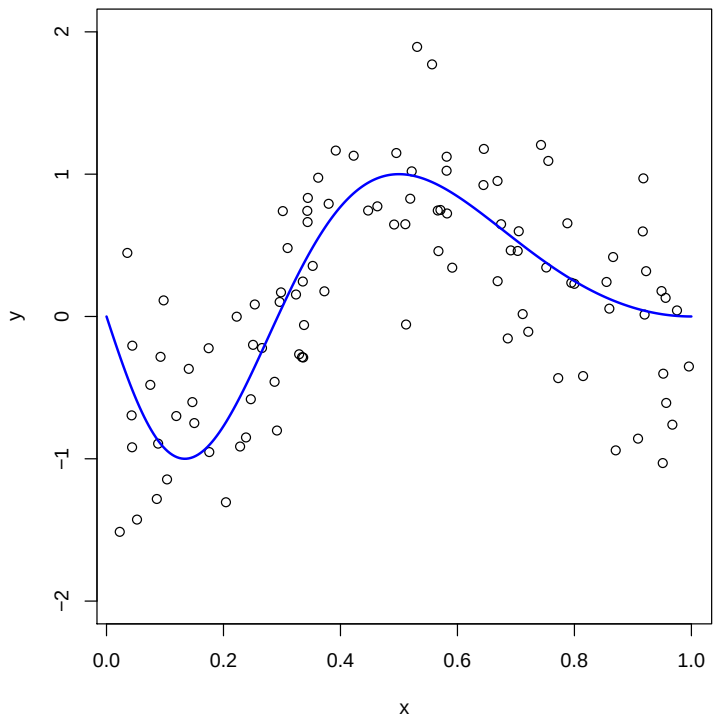

El problema del modelado

Lamentablemente, en la práctica **sólo** disponemos de los datos observados:

$$(x_1, Y_1), (x_2, Y_2), \ldots, (x_{100}, Y_{100}),$$

el primer paso es hacer un análisis exploratorio:

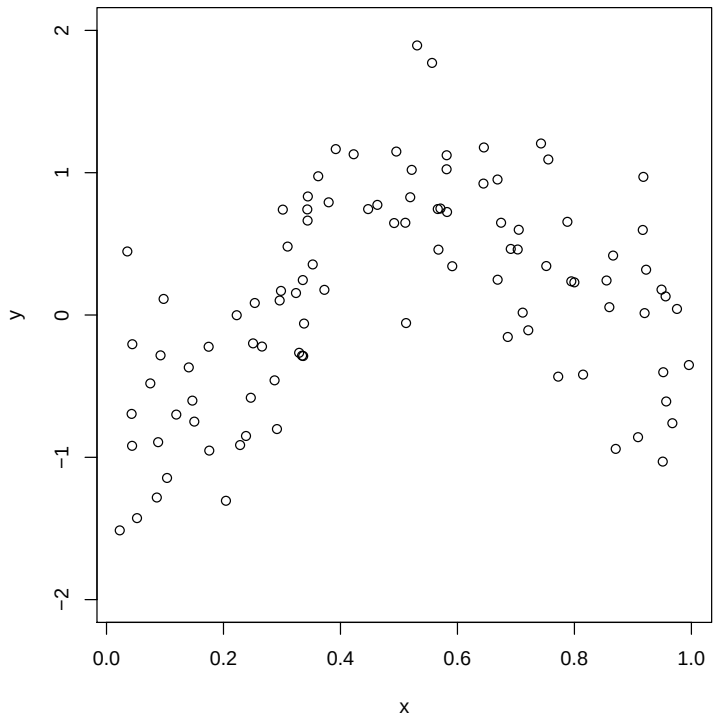

El problema del modelado

El analista propone el modelo:

$$Y_i = g(x_i) + \epsilon_i, \qquad i = 1, \ldots, 100,$$

y su objetivo es "estimar" la función $g(\cdot)$ desde los datos, obteniendo

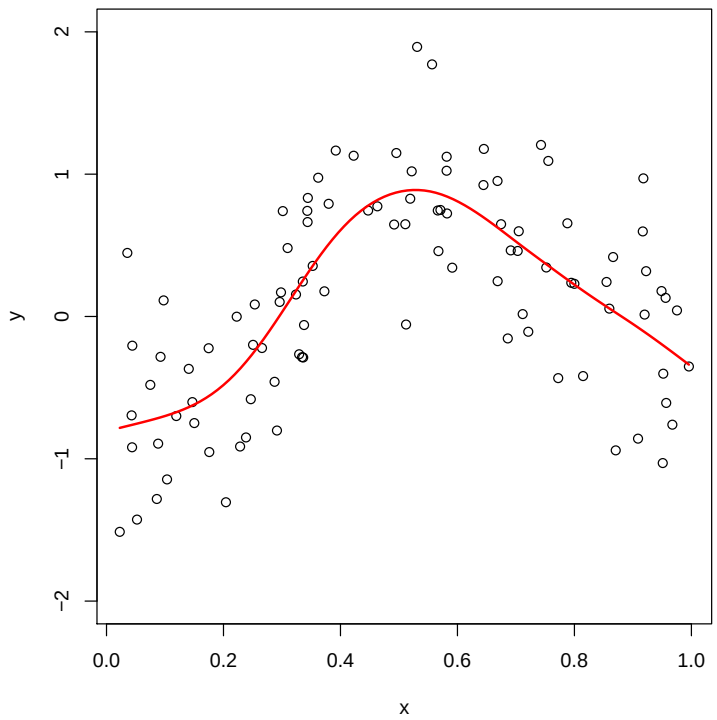

El problema del modelado

En Estadística se estudia teóricamente, la "bondad del modelo" comparando

$$\widehat{Y} = \widehat{g}(x), \qquad \text{v.s.} \qquad Y = \operatorname{sen}\{2\pi(1-x)^2\},$$

esto es, el modelo ajustado v.s. el modelo subyacente (verdadero).

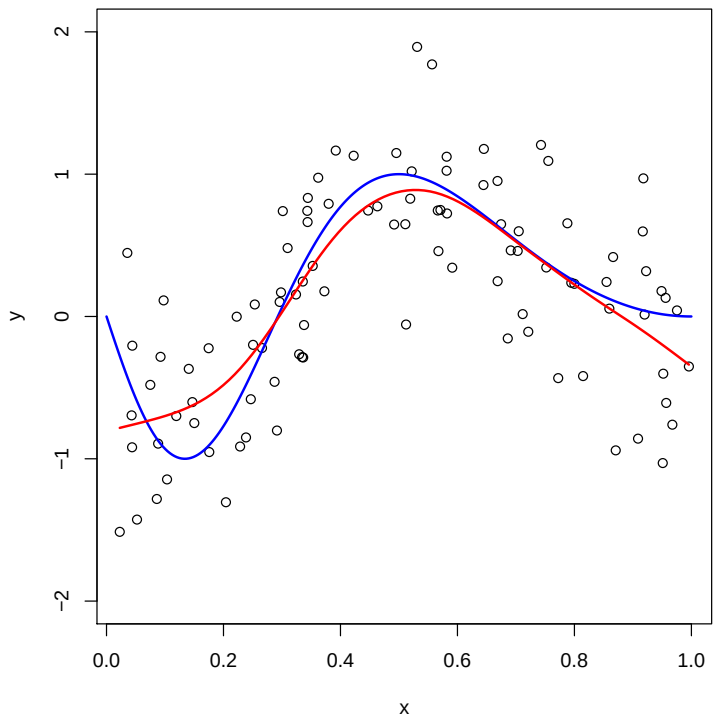

Esquema de Modelación Estadística

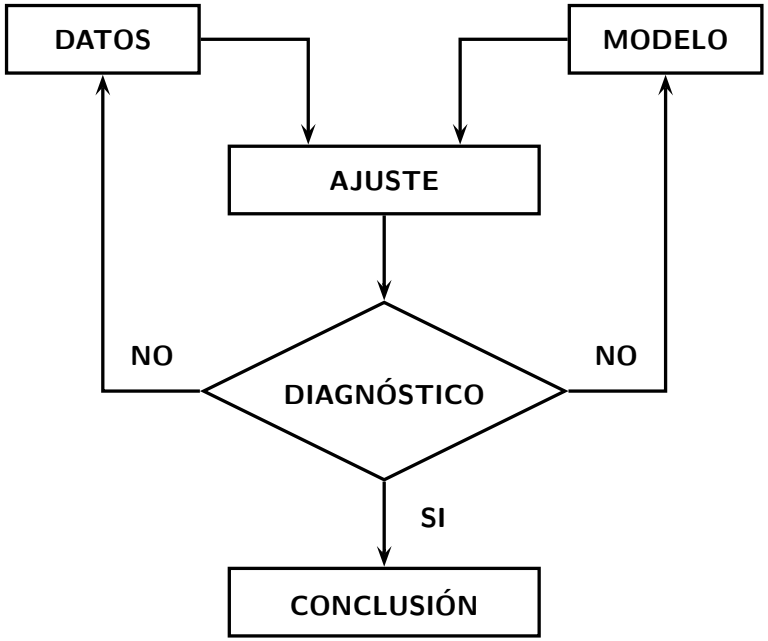

Recolección de datos: Muestreo.

Análisis exploratorio de datos.

Análisis Multivariado.

Técnicas de Regresión.

Series de Tiempo, entre (muchas) otras.

Inferencia Estadística.

Bondad de ajuste, técnicas gráficas.

Análisis de Sensibilidad.

Comunique sus resultados!