AES519: Estadísticas de resumen

Felipe Osorio

https://faosorios.github.io

Instituto de Matemática Fisica y Estadística, UDLA

Estadísticas de resumen

Ingredientes:

Conjunto de n observaciones $\{x_1, x_2, \ldots, x_n\}$ conocidas como muestra.

En general, nuestro interés recaerá en resúmenes de la información a través de una **estadística**, digamos $T = T(x_1, \ldots, x_n)$.

En esta clase consideraremos 3 tipos de estadísticas de resumen[1] para una muestra $\boldsymbol{x} = (x_1, \ldots, x_n)^\top$,

- medidas de posición.
- medidas de dispersión.
- medidas de forma (asimetría y curtosis).

[1] En ocasiones escribiremos $T = T(\boldsymbol{x})$.

Definición 1 (Media muestral o promedio):

Sea $x_1, \ldots, x_n$ valores muestrales. Se define el promedio o media muestral como:

$$\overline{x} = \frac{1}{n}(x_1 + x_2 + \cdots + x_n) = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

Suponga que la observación i-ésima, digamos x_i, se repite n_i veces. Entonces tenemos

$$\overline{x} = \frac{1}{n}\sum_{i=1}^{n} n_i x_i.$$

En general, considere "pesos" $\omega_1, \ldots, \omega_n$ asociados a las observaciones $x_1, \ldots, x_n$. En este caso,

$$\overline{x} = \frac{1}{\sum_{j=1}^{n} \omega_j}\sum_{i=1}^{n} \omega_i x_i.$$

Ejemplo:

Considere el conjunto de datos $\boldsymbol{x} = \{1, 2, 2, 2, 3, 3, 8\}$. Tenemos $n = 7$, y

$$\begin{aligned}\sum_{i=1}^{7} x_i &= 1 + 2 + 2 + 2 + 3 + 3 + 8 \\ &= 1 + 2 \cdot 3 + 2 \cdot 3 + 8 = 21,\end{aligned}$$

así $\overline{x} = 21/7 = 3$. Note también que el gráfico de tallo y hoja, adopta la forma:

1	*		
2	*	*	*
3	*	*	
4			
5			
6			
7			
8	*		

Ejemplo (datos de accidentes):

Suponga el siguiente conjunto de datos:

Número de accidentes (x_i)	Frecuencia (f_i)	$f_i x_i$
0	55	0
1	14	14
2	5	10
3	2	6
4	0	0
Total	76	30

De este modo, $\overline{x} = 30/76 = 0{,}3947$ es el número promedio de accidentes.

Definición 2 (Estadísticos de orden):

Sea $x_1, \ldots, x_n$ una muestra. Entonces los valores ordenados

$$x_{(1)} \leq x_{(2)} \leq \cdots \leq x_{(n)},$$

se denominan estadísticos de orden. Algunas estadísticas de orden son: el mínimo muestral $x_{(1)}$, el máximo muestral $x_{(n)}$.

Definición 3 (Mediana):

Sea $x_{(1)}, \ldots, x_{(n)}$ observaciones ordenadas. La mediana es definida como:

$$\mathrm{me}(\boldsymbol{x}) = \begin{cases} x_{(r)}, & n \text{ es impar}, \\ \dfrac{x_{(n/2)} + x_{(n/2+1)}}{2}, & n \text{ es par}, \end{cases}$$

con $r = (n+1)/2$.

Medidas de dispersión

Considere los siguientes conjuntos de datos:

$$D_1 = \{10, 20, 30\}, \qquad D_2 = \{5, 5, 20, 35, 35\}, \qquad D_3 = \{20, 20, 20\},$$

Tenemos los gráficos de tallo-y-hoja:

Datos D_1:

5	
10	*
15	
20	*
25	
30	*
35	

Datos D_2:

5	* *
10	
15	
20	*
25	
30	
35	* *

Datos D_3:

5	
10	
15	
20	* * *
25	
30	
35	

Considere $\overline{x}_j$ y me_j el promedio y la mediana asociada al conjunto de datos D_j para $j = 1, 2, 3$. Entonces,

$$\begin{aligned}
\overline{x}_1 &= \frac{1}{3}(10 + 20 + 30) = \frac{60}{3} = 20, \\
\overline{x}_2 &= \frac{1}{5}(2 \cdot 5 + 20 + 2 \cdot 35) = \frac{100}{5} = 20, \\
\overline{x}_3 &= \frac{3 \cdot 20}{3} = 20.
\end{aligned}$$

Además, $\mathrm{me}_j = 20$ para todo j.

Observación:

Es decir, tenemos tres configuraciones de datos con valores centrales idénticos.

Medidas de dispersión

Sean Q_1 y Q_3 las medianas de la mitad inferior y superior de los datos, conocidos como el 1er y 3er cuartiles, respectivamente. Esto permite definir:

$$IQR = Q_3 - Q_1,$$

que es conocido como rango intercuartílico.

También podemos considerar el rango de la muestra como:

$$\begin{aligned} R &= \text{máx}\{x_1, \ldots, x_n\} - \text{mín}\{x_1, \ldots, x_n\} \\ &= x_{(n)} - x_{(1)}. \end{aligned}$$

Medidas de dispersión

Considere subdividir los datos ordenados $x_{(1)}, \ldots, x_{(n)}$ en secciones de 100 %, llamados percentiles. Entonces el percentil de orden j $(1 \leq j \leq 100)$ está dado por:

$$P_j = x_{(j(n+1)/100)}.$$

Note que $Q_1 = P_{25}$, la mediana (o 2º cuartil, Q_2) es $\mathrm{me} = P_{50}$ y $Q_3 = P_{75}$.

Ejemplo:

Considere el conjunto de datos $\boldsymbol{x} = \{4, 7, 18, 1, 7, 13, 2\}$ y suponga que deseamos calcular el rango intercuartílico IQR.

Primeramente es necesario ordenar el conjunto de datos:

$$\{x_{(1)}, x_{(2)}, x_{(3)}, x_{(4)}, x_{(5)}, x_{(6)}, x_{(7)}\} = \{1, 2, 4, 7, 7, 13, 18\}.$$

Disponemos de $n = 7$ datos, luego para obtener el 1er y 3er cuartiles podemos usar

$$Q_1 = P_{25} = x_{(25\cdot(7+1)/100)} = x_{(1\cdot 8/4)} = x_{(2)} = 2,$$
$$Q_3 = P_{75} = x_{(75\cdot(7+1)/100)} = x_{(3\cdot 8/4)} = x_{(6)} = 13.$$

De este modo, $IQR = Q_3 - Q_1 = 13 - 2 = 11$.

Definición 4 (Varianza muestral):

Considere $x_1, \ldots, x_n$ valores observados, se define su varianza muestral como:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \overline{x})^2.$$

Observación:

$s = \sqrt{s^2}$ se denomina desviación estándar.

Notación:

En ocasiones escribiremos $\mathrm{var}(\boldsymbol{x})$ para denotar s^2.

Propiedades del promedio y varianza muestrales

Propiedades:

(a)

$$\sum_{i=1}^{n}(x_i - \overline{x}) = 0.$$

(b)

$$\sum_{i=1}^{n}(x_i - \overline{x})^2 = \sum_{i=1}^{n} x_i^2 - n\overline{x}^2$$

(c)

$$\mathrm{var}(c) = 0.$$

(d) Sea $x_1, \ldots, x_n$ y considere la transformación:

$$y_i = a\, x_i + b, \qquad i = 1, \ldots, n.$$

Entonces $\overline{y} = a\,\overline{x} + b$ y $s_y^2 = a^2 s_x^2$.

Observación:

Un caso particular de importancia es la estandarización del conjunto de datos $\{x_1, \ldots, x_n\}$, definida como:

$$z_i = \frac{x_i - \overline{x}}{s}, \qquad i = 1, \ldots, n.$$

Entonces,[2]

$$\overline{z} = 0 \qquad \text{y} \qquad s_z^2 = 1.$$

[2] Basta hacer $a = 1/s$ y $b = \overline{x}/s$ en la Propiedad (d).

Definición 5 (Coeficiente de variación):

Este coeficiente es una medida que compara la desviación estándar con el promedio de una muestra y es definido como

$$\mathrm{CV} = s/\overline{x}, \qquad \overline{x} \neq 0.$$

El coeficiente es particularmente útil para comparar dos o más muestras (o grupos).

Observación:

Un valor pequeño para el CV está asociado a una muestra homogénea.

Observación:

En Econometría $1/\mathrm{CV}$ es conocido como la razón de Sharpe.

Medidas de forma

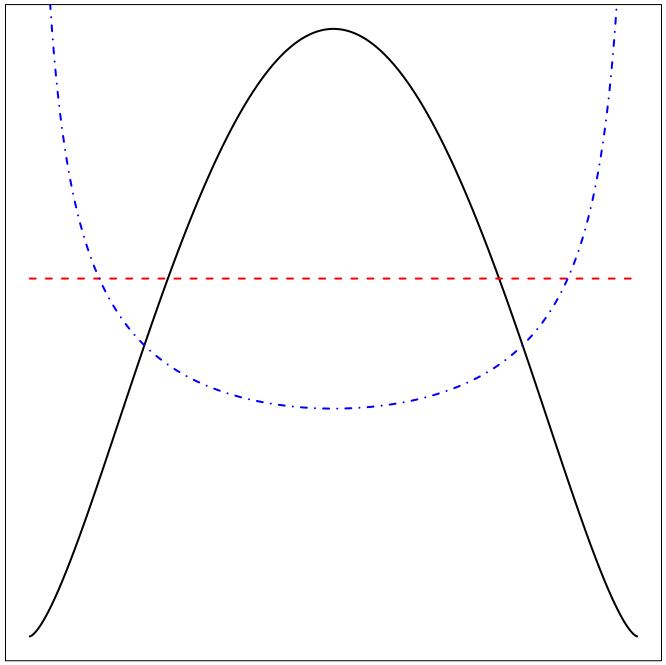

(a) distribuciones simétricas

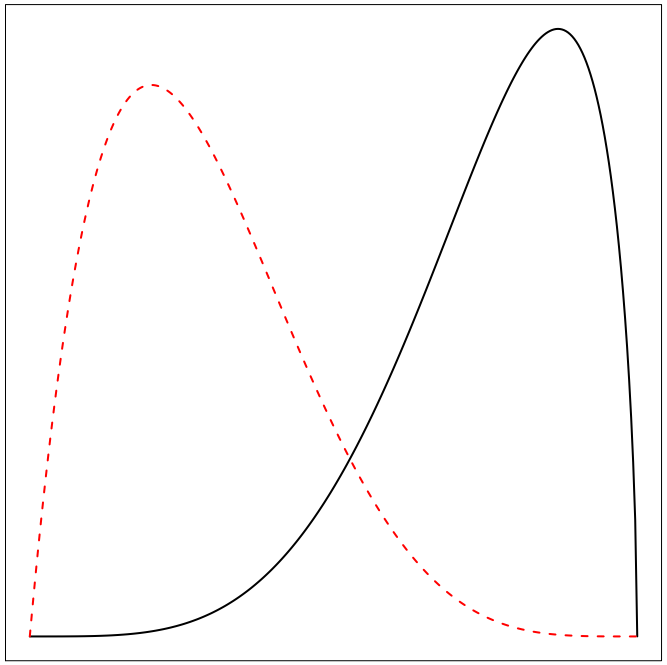

(b) asimetría negativa (–), positiva (- -)

Definición 6 (Coeficiente de asimetría):

Considere m_3 el tercer momento muestral, entonces se define el coeficiente de asimetría (o sesgo) como:

$$b_1 = \frac{m_3}{s^3} = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{x_i - \overline{x}}{s}\right)^3.$$

Observación:

- Si $b_1 = 0$ la distribución es simétrica con relación a $\overline{x}$.
- Si $b_1 > 0$ la distribución tiene sesgo positivo. En caso contrario, decimos que tiene sesgo negativo.

Observación:

Se han definido diversos índices de simetría, por ejemplo la medida de sesgo de Galton:

$$b_{\mathsf{G}} = \frac{(Q_3 - Q_2) - (Q_2 - Q_1)}{Q_3 - Q_1}.$$

Medidas de forma

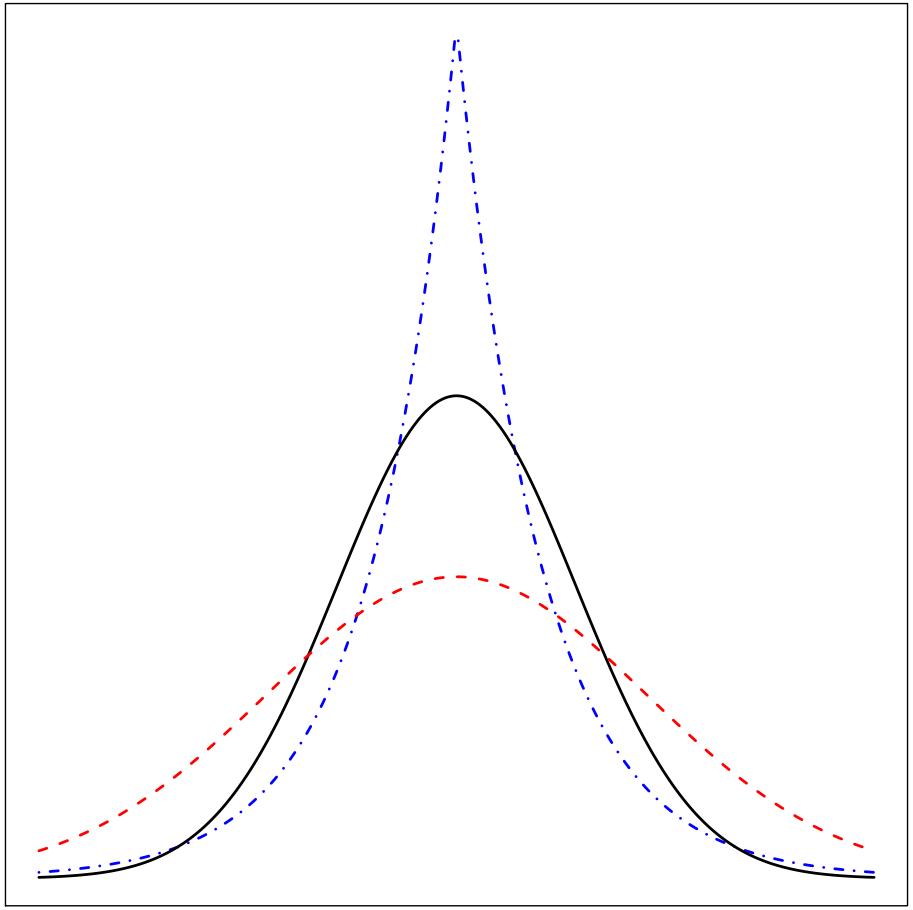

(a) Distribución leptocúrtica (– · –), mesocúrtica (—) y platicúrtica (– –)

Definición 7 (Coeficiente de curtosis):

Considere m_4 el cuarto momento muestral, entonces se define el coeficiente de curtosis[3] como:

$$b_2 = \frac{m_4}{s^4} - 3 = \left\{ \frac{1}{n} \sum_{i=1}^{n} \left(\frac{x_i - \overline{x}}{s} \right)^4 \right\} - 3.$$

Observación:

El término -3 hace que $b_2 = 0$ cuando los datos siguen una distribución normal.

[3] también conocido como exceso de curtosis

Datos del SIMCE: Puntajes de matemáticas[4]

```
> z <- quantile(x)
> z
    0%    25%    50%    75%   100%
 87.74 226.32 263.96 299.29 369.55

> sd(x)  # desviación estándar
[1] 51.79042
> var(x) # varianza
[1] 2682.247

> library(fastmatrix) # https://faosorios.github.io/fastmatrix
> moments(x)
$second
[1] 2682.227
$third
[1] -30409.6
$fourth
[1] 18784749
$skewness
[1] -0.2189084
$kurtosis
[1] -0.3889947

```

[4] $n = 132\,793$ observaciones, así que $(n-1)/n = 0{,}9999925$.
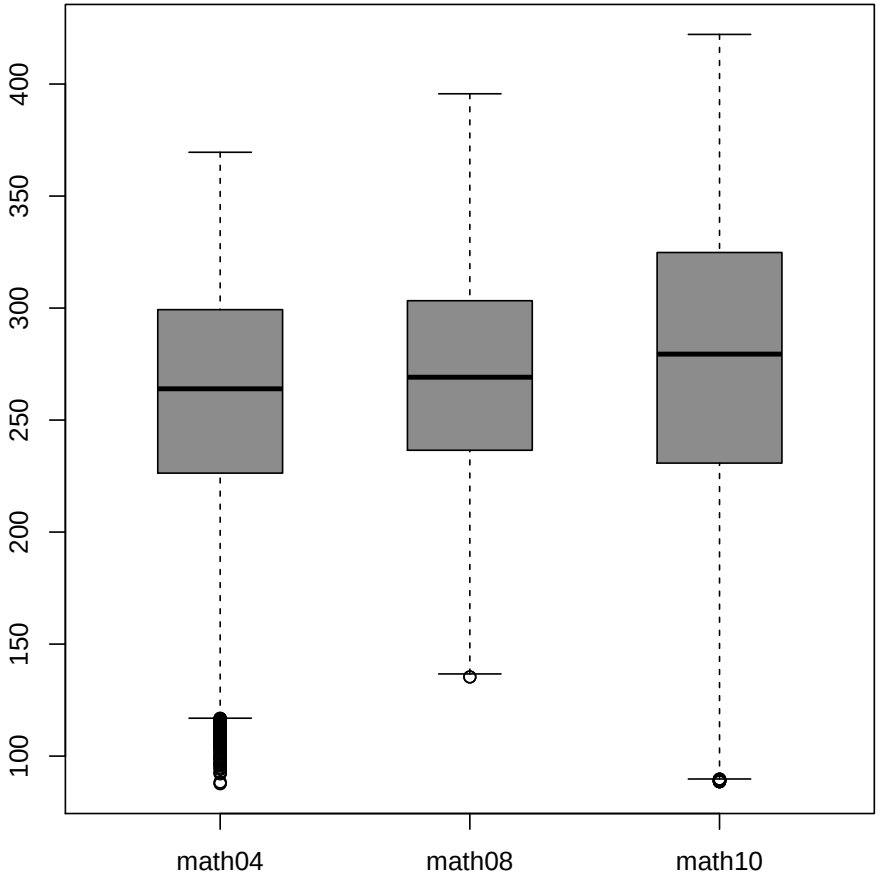
Gráfico de cajón con bigotes (boxplot)